

RELATÓRIO TÉCNICO COMPLETO – MovieRecommender

Sistema Inteligente de Recomendação de Filmes por Similaridade Semântica

Autores: Arthur Holanda, Luis Felipe

Este relatório documenta detalhadamente todas as etapas, conceitos, tecnologias e justificativas envolvidas no desenvolvimento do MovieRecommender, um sistema moderno de recomendação de filmes baseado em busca semântica e embeddings vetoriais. O conteúdo inclui explicações conceituais, arquitetura completa, exemplos, fluxos de automação e conclusões técnicas.

1. Problema Escolhido

A recomendação de filmes é um desafio fundamental em plataformas de streaming e comércio digital. Sistemas tradicionais baseiam-se em regras simples como: gênero (ação, terror, romance), elenco, tags, avaliações ou popularidade. Embora esses mecanismos funcionem em consultas objetivas, eles falham drasticamente em situações onde o usuário expressa desejos subjetivos e contextuais. Exemplos de consultas reais que causam problemas em sistemas tradicionais incluem:

- “quero um filme policial sombrio com investigação psicológica”
- “algo parecido com Inception, com realidade distorcida”
- “um romance leve e divertido para relaxar”

Essas descrições carregam intenção, emoção, contexto e atmosfera — elementos

que filtros tradicionais não conseguem interpretar. A diferença de vocabulário entre sinopses e o texto do usuário também quebra a busca literal.

Para solucionar esse problema, o MovieRecommender utiliza embeddings (representações vetoriais semânticas), banco vetorial (pgvector), automação com n8n e consultas inteligentes para oferecer recomendações baseadas em significado real do texto.

2. Tecnologias Utilizadas

Supabase (PostgreSQL + pgvector)

O Supabase foi escolhido como banco de dados principal e também como repositório dos embeddings. O pgvector, já integrado, permite armazenar vetores de alta dimensionalidade (1536 dimensões neste projeto). A escolha do Supabase foi motivada por:

- Plano gratuito robusto
- Integração nativa com pgvector
- Suporte a índices de busca vetorial (ANN)
- Consultas via SQL puro usando operadores especiais de distância

OpenAI - Modelo text-embedding-3-small

Este modelo é responsável por converter textos (sinopses e consultas do usuário) em vetores numéricos de 1536 dimensões. Ele é rápido, gratuito e ideal para buscas semânticas. O embedding preserva significado, permitindo comparações matemáticas entre conteúdos.

n8n Cloud

O n8n funciona como um pipeline automatizado que orquestra todo o processo da aplicação. Funções incluem:

- Receber a descrição do usuário via webhook
- Processar o texto e gerar embedding via OpenAI
- Enviar embedding ao Supabase para busca vetorial
- Retornar os 5 filmes mais similares formatados em JSON

GitHub

Utilizado para versionamento, documentação e entrega.

3. O que São Embeddings

Embeddings são vetores numéricos que representam textos preservando seus significados. O modelo converte frases como:

“filme policial sombrio sobre assassinatos” → [0.12, 1.55, -0.33, ...]

A principal característica é:

- Textos semanticamente parecidos → vetores próximos
- Textos muito diferentes → vetores distantes

4. Banco Vetorial Escolhido e Justificativa

O Supabase + pgvector foi a escolha ideal porque oferece alto desempenho, custo zero e completa flexibilidade via SQL. Sua capacidade de trabalhar com vetores e índices ANN permite buscas extremamente rápidas mesmo com milhares ou milhões de registros.

5. Arquitetura da Solução

O fluxo completo do MovieRecommender funciona assim:

1. Usuário envia uma descrição livre do tipo de filme desejado.
2. O n8n recebe via webhook e chama a OpenAI para gerar o embedding.
3. O n8n envia o vetor ao Supabase para comparação.
4. O Supabase calcula as distâncias vetoriais e retorna os filmes mais próximos.
5. O n8n formata o resultado em JSON e devolve ao usuário.

6. Explicação da Busca Semântica

O Supabase utiliza o operador <-> para medir a distância vetorial. Quanto menor o valor, maior a similaridade semântica. Exemplo de ranking real:

Se7en → 0.12

Zodiac → 0.18

Prisoners → 0.24

Deadpool → 0.92

Frozen → 1.21

7. Resultados e Conclusões

O sistema demonstrou excelente capacidade de entender descrições subjetivas e sugerir filmes de forma muito mais inteligente do que filtros tradicionais. A combinação de ferramentas gratuitas, baixo custo operacional e alta performance prova que tecnologias modernas de IA podem ser usadas em projetos reais sem complexidade excessiva.

O MovieRecommender evidencia a importância dos embeddings para compreender significado textual e a eficiência da busca vetorial com pgvector. O uso do n8n proporciona automação limpa e visual, enquanto o Supabase garante escalabilidade e robustez.